# DeepSeek-Series-Paper

Foundation Model:

1. 2024-01: DeepSeek LLM Scaling Open-Source Language Models with Longtermism(Reproducing Meta LLaMa)
2. 2024-05: DeepSeek-V2(236B, Activated 21B): A Strong, Economical, and Efficient Mixture-of-Experts Language Model(MHA, Low-Rank Key Value Joint Compression )
3. 2024-12: DeepSeek-V3(671B 37B Activated 1 + 256) Technical Report(MTP + Speculative Decoding + FP8 mixed precision training + RL(Rule-Based RM + Model-Based RM))

Reasoning Model:

4. 2024-01: DeepSeek-Coder: When the Large Language Model Meets Programming - The Rise of Code Intelligence
5. 2024-02: MATH-SHEPHERD: VERIFY AND REINFORCE LLMS STEP-BY-STEP WITHOUT HUMAN ANNOTATIONS(PRM Test Time Scaling)
6. 2024-04: DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models(RL: GRPO)
7. 2024-05: DeepSeek-Prover: Advancing Theorem Proving in LLMs through Large-Scale Synthetic Data(Lean Math proof verfication)
8. 2025-07:  DeepSeek-Prover-V2(671B): Advancing Formal Mathematical Reasoning via Reinforcement Learning for Subgoal Decomposition(Lean 4)
9. 2025-01: DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning
10. 2025-12: DeepSeek-V3.2: Pushing the Frontier of Open Large Language Models(DeepSeek Sparse Attention (DSA))
11. 2026-01: mHC: Manifold-Constrained Hyper-Connections
12. 2026-01: Conditional Memory via Scalable Lookup: A New Axis of Sparsity for Large Language Models(Engram/DSE)
13. 2026-04: DeepSeek-V4(1.6T 49B): Towards Highly Efficient Million-Token Context Intelligence

**DeepSeek LLM 2024-01 : https://arxiv.org/pdf/2401.02954 本文是对meta llama2 的复现**

- 数据与llama2不太一样，deepseek主要以中文为主。
- 整个模型结构、包括一些fine-tuning的方法跟llama2一致
- 模型的7B、67B的参数量也是对标的llama2 的7B、70B两种参数的模型
- scaling laws 超参数研究：对scaling law做了更精细的研究并提出一个新的公式（很多其他公司或论文就直接用经验值）
- 诚实讲刷榜的问题：只要给大模型喂题，大模型对应的榜单分数会高出一大截

**DeepSeek MoE 2024-01 https://arxiv.org/pdf/2401.06066 Dense Model: MoE**

- dense model 和 MoE的区别：
  - dense model 普通的transformer
  - MoE transformer的神经网络分成好几份，每一份都是一个专家，一个问题过来，只用对应的专家，又叫稀疏模型。
- MoE带来成本的下降，模型可以训很大，但是使用时只用激活部分参数
- 这篇文章是一个study，相当于为deepseek v2铺路，文章里面只完全训练了一个2B,16B的模型
- 创新点：
  - 之前的MoE只有8或16个专家（不同的专家区分不明显），但是deepseek的专家分得更细，本篇用了64个expert，更稀疏，且每个专家更细粒度。之前的MoE，每个专家都要学很多东西，每个专家区分不明显；deepseek专家更细粒度。
  - 同时deepseek还设置了share的专家，不管什么知识过来，都过一下share的专家

**DeepSeek-V2 2024-05 https://arxiv.org/pdf/2405.04434 236B MoE 激活 21B**

•创新点：提出 Multi-Head Latent Attention（MLA），节约93.3%KV cache

- Figure 3从左到右：从MHA到GQA 到MQA，随着K-V对的减少，performance也会下降，KV存在GPU里。DeepSeek提出的Multi-Head Latent Attention，存储的时候，将多头注意力的KV做了压缩再存，把KV cache降低了93.3%

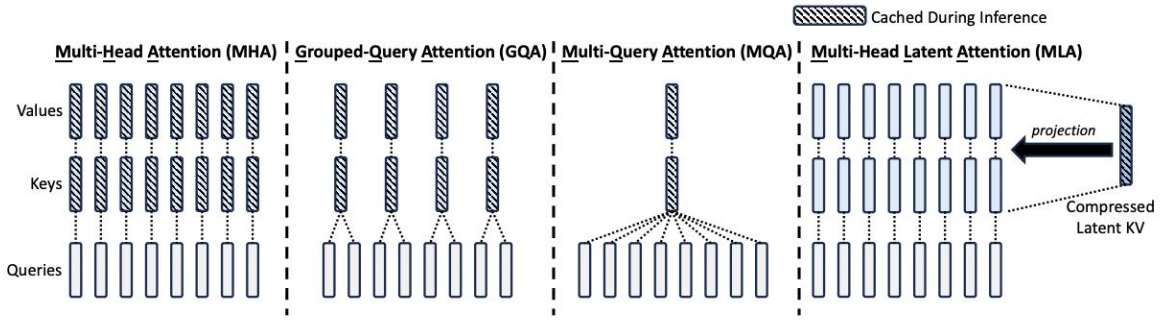



Figure 3 | Simplified illustration of Multi-Head Attention (MHA), Grouped-Query Attention (GQA), Multi-Query Attention (MQA), and Multi-head Latent Attention (MLA). Through jointly compressing the keys and values into a latent vector, MLA significantly reduces the KV cache during inference.

•技术细节：

- 工程上，做了experts、device、communication 三方面的平衡，即平衡被激活的experts，平衡训练时用的GPU，进一步提升效率。同时MoE的多experts的设置天然就适合分布式。
- 整体模型训练用了8.1T tokens，其中，中文tokens比英文tokens多了接近12%。

**DeepSeek-V3 2024-12 https://arxiv.org/pdf/2412.19437 671B MoE 激活 37B**

(train了14.8T的token。训练成本，整体花费557.6万美元。训练很稳定，一次train完，没有回滚，deepseek的infra做得特别好)

•V3相比V2，使用了multi-token prediction（MTP），一次性预测接下来3个词，好处是让模型的训练更稠密，且另一方面是，模型可以更好的去自己规划即将预测的词。这个MTP是另一篇论文提出来的，也很新。

•1个shared专家，256个experts

•强化学习的reward model，开始用了基于规则的奖励模型（rule-based RM），之前都是model-base RM

•文章写了好几页的infra，介绍工程实践

**DeepSeek-Coder 2024-01 https://arxiv.org/pdf/2401.14196**

是一系列开源的大型语言模型（LLMs），旨在提升代码智能，该系列模型的规模从 1.3B 到 33B 参数不等。

•DeepSeek Coder，从头开始训练 2T个Tokens，专注于增强代码生成和填充能力

•DeepSeek Coder-v1.5，在DeepSeek-LLM-7B的基础上，继续用2T的tokens做预训练（continue pre-training）

•两个版本的Coder代码都开源

**DeepSeek-Coder-V2 2024-06 https://arxiv.org/pdf/2406.11931**

在 DeepSeek-V2 的基础上，进一步预训练了 6T tokens

•本篇强化学习的reward model，依然是model-base的

**DeepSeek-Math-Shepherd 2024-02 https://arxiv.org/pdf/2312.08935**

•背景：

- openai发表过一篇论文《let's verify step by step》，引导后续研究往“过程监督”的reward model路径上靠拢。
- 过程监督：数学推理中有很多的步骤，大家希望有个模型告诉我，过程中的每一步骤对不对。（对应的“结果监督”，只监测结果对不对）
- open-ai引入了一个过程监督数据集（PRM800K），这个数据集靠人工标注了80万个步骤级正确性标签，每个步骤都被赋予了正向、负向或中性的评分，以反映其在解决数学问题中的有效程度。

•DeepSeek工作：

- 不需要人类标注结果，自动的构建每个步骤是否正确的标签。
- 构建方法：先生成一个步骤，然后固定该步骤，让模型生成后面的多种步骤结果，最终有多种不同的solution，假设“固定的这个步骤”能高概率引导出正确答案，那么认为“固定的这个步骤”正确；如果“固定的这个步骤”怎么写都写不出正确答案，那么“固定的这个步骤”错误。
- 结果：对比标注数据 和 自动构建的数据，结果表现差不多。

**DeepSeek-Math 2024-04** https://arxiv.org/pdf/2402.03300

DeepSeekMath 7B 是一个专注于数学推理的语言模型，通过在DeepSeek-Coder-Base-v1.5 7B的基础上，使用120B数学相关token进行预训练，显著提升了数学推理能力。

**数据源**：从Common Crawl中筛选数学相关网页内容，构建了高质量的预训练数据集——**DeepSeekMath Corpus**（120B数学相关的Token）。

**模型架构**：

- **代码能力迁移**：模型基于代码预训练模型DeepSeek-Coder-Base-v1.5 7B初始化。实验表明，代码训练显著提升了数学推理表现（即使不使用工具），验证了代码能力对数学问题解决的正向迁移。
- **强化学习优化**：提出**Group Relative Policy Optimization (GRPO)**，一种改进的PPO方法，显著降低内存占用同时提升数学推理能力。经GRPO优化后，模型在MATH基准测试的准确率从46.3%提升至51.7%（接近GPT-4的60.9%）。

  改进方式简述：

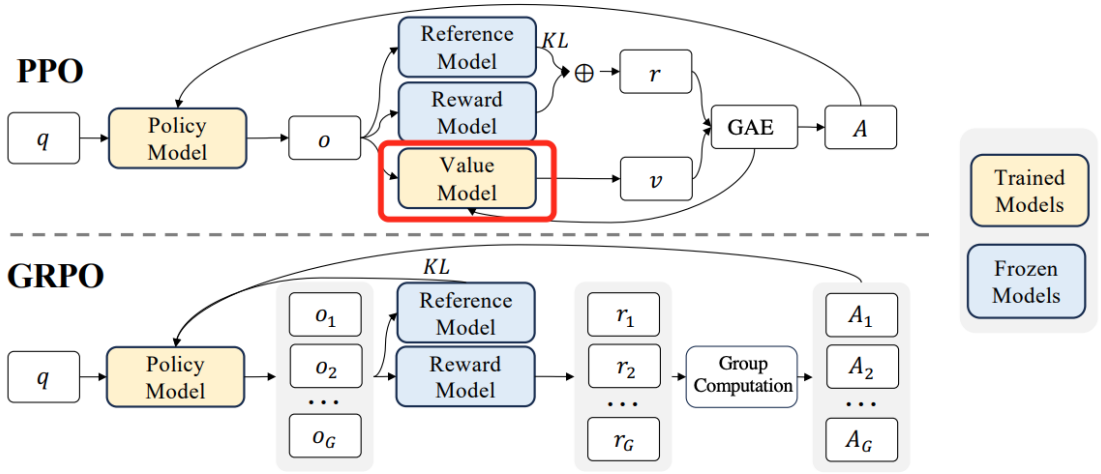



Figure 4 | Demonstration of PPO and our GRPO. GRPO foregoes the value model, instead estimating the baseline from group scores, significantly reducing training resources.

- **讨论**：开始讨论如何泛化reward model的能力

**DeepSeek-Prover 2024-05 https://arxiv.org/pdf/2405.14333**

DeepSeek-Prover论文提出了一种利用大规模合成数据增强大语言模型（LLMs）在形式化定理证明中能力的方法，核心内容如下：

1.**现有问题**：现有LLMs在形式化定理证明（如使用Lean 4验证器）中存在性能瓶颈，主要受限于**高质量形式化证明数据的缺乏(**Lean 是一种专门服务于定理证明的编程语言 https://lean-lang.org/about/）

2.**方法创新**

•**数据生成**：

- 将**高中数学竞赛题和本科数学问题**转化为形式化陈述（基于Lean 4，这是一个引擎，简单理解就是判断“形式化陈述”对不对）。
- 通过**质量评分模型**（过滤低质量陈述）和**假设拒绝策略**（验证陈述有效性）筛选数据。
- 使用迭代框架生成**800万条形式化陈述-证明对**的合成数据集。

•**训练优化**：

- **并行证明搜索**：为每个陈述同时搜索其原始形式与否定形式的证明，任一得证即终止，**加速搜索过程**。
- **迭代增强**：通过多次微调（每轮用新数据训练模型），逐步提升模型生成高质量证明的能力。

•**效果：**在**Lean 4 miniF2F测试**中，模型全证明生成准确率达46.3%（64样本）、52%（累积），显著超越GPT-4（23%）与树搜索强化学习方法（41%）。

•注意，本文开始讨论不要reward model

**DeepSeek-Prover-V1.5 2024-08 https://arxiv.org/pdf/2408.08152**

- **核心目标**：通过融合强化学习（RL）和蒙特卡洛树搜索（MCTS）(历史弯路)改进定理证明的交互式策略。
- 与传统RL依赖“训练好的奖励模型”不同，DeepSeek-Prover-V1.5直接通过Lean证明助手的严格验证结果生成二元奖励（成功验证为1，失败为0），没有使用独立的奖励模型。

**Rewards.** When training LLMs via RL, a trained reward model typically provides feedback signals. In contrast, formal theorem proving benefits from the rigorous verification of generated proofs by proof assistants, offering a significant advantage. Specifically, each generated proof receives a reward of 1 if verified as correct, and 0 otherwise. While this binary reward signal is accurate, it is also sparse, especially for theorems that are challenging for the supervised fine-tuned model. To mitigate this sparsity, we select training prompts that are challenging yet achievable for the supervised fine-tuned model, as described above.

**DeepSeek-R1 2025-01 https://arxiv.org/pdf/2501.12948**

为了训练DeepSeek-R1-Zero，DeepSeek采用了基于规则的奖励系统，主要包括两种类型的奖励：

- **准确性奖励**：准确性奖励模型评估回答是否正确。例如，对于结果确定的数学问题，模型需按照指定格式（如答案放入框内）提供最终答案，便于基于规则的可靠验证。
- **格式奖励**：除了准确性奖励模型，我们使用格式奖励模型强制要求模型的思考过程必须位于<think>和</think>标签之间。缓解多语言提示下推理过程的语言混合问题。

### 2.2.2. *Reward Modeling*

The reward is the source of the training signal, which decides the optimization direction of RL. To train DeepSeek-R1-Zero, we adopt a rule-based reward system that mainly consists of two types of rewards:

- **Accuracy rewards**: The accuracy reward model evaluates whether the response is correct. For example, in the case of math problems with deterministic results, the model is required to provide the final answer in a specified format (e.g., within a box), enabling reliable rule-based verification of correctness. Similarly, for LeetCode problems, a compiler can be used to generate feedback based on predefined test cases.
- **Format rewards**: In addition to the accuracy reward model, we employ a format reward model that enforces the model to put its thinking process between '<think>' and '</think>' tags.